

Implementasi Arsitektur Retrieval-Augmented Generation (RAG) pada Sistem Temu Kembali Informasi Dokumen Penyuluhan Pertanian

Warsila Agimnastiar Nawir¹, Sitti Fatima², Jumrianti³, Muh. Aksa⁴, Safri Nur Saputra⁵, Aryaguna Nugraha Passuleri⁶

¹Teknologi Produksi Industri, Program Studi Ilmu Komputer, Institut Teknologi Bacharuddin Jusuf Habibie, Parepare, Indonesia

Email: ¹warsilaagimnastiarnawir.231011116@mahasiswa.ith.ac.id, ²sittifatima.231011092@mahasiswa.ith.ac.id,
³jumrianti.231011007@mahasiswa.ith.ac.id, ⁴muhaksa.231011101@mahasiswa.ith.ac.id,
⁵saftrinursaputra.231011086@mahasiswa.ith.ac.id, ⁶aryanugrahapassuleri.231011022@mahasiswa.ith.ac.id

Abstrak— Sektor pertanian di wilayah Parepare, khususnya komoditas padi dan jagung, menghadapi kendala serius dalam distribusi informasi penyuluhan akibat fenomena *Semantic Gap* (kesenjangan semantik). Petani yang menggunakan sapaan dan bahasa keseharian sering kali gagal menemukan informasi teknis di dalam dokumen pedoman resmi jika hanya mengandalkan pencarian kata kunci konvensional. Penelitian ini bertujuan untuk menguji tingkat presisi penelusuran semantik lintas bahasa alami melalui pengembangan sistem *Question-Answering* (QA) bernama AGRO-TANYA yang mengimplementasikan arsitektur *Retrieval-Augmented Generation* (RAG). Korpus data dibangun secara mandiri mengekstrak 1.332 dokumen PDF jurnal pertanian portal Garuda menjadi 20.200 baris paragraf informasi pertanian terstruktur. Pengujian komparatif dilakukan terhadap tiga arsitektur *Dense Vector Embedding*: *paraphrase-multilingual-MiniLM-L12-v2*, *intfloat/multilingual-e5-large*, dan *BAAI/bge-m3*. Hasil evaluasi kuantitatif menunjukkan model *BAAI/bge-m3* berdimensi 1024 memberikan performa superior dengan perolehan skor *Mean Reciprocal Rank* (MRR) sebesar 0,667, *Precision@3* sebesar 0,56, serta *HitRate@3* mencapai 66,7%, jauh mengungguli model *baseline* MiniLM yang mengalami kegagalan total akibat *vocabulary mismatch*. Pada komponen generasi teks, integrasi model *Gemini 2.5 Flash* dengan teknik *Advanced Prompt Engineering* terbukti secara empiris mampu menyintesis jawaban yang faktual, terlokalisasi dengan sapaan akrab Bugis-Makassar, serta bebas dari halusinasi data. Di sisi keandalan rekayasa, penerapan strategi *Asymmetric Context Window* serta mekanika *Graceful Degradation* berhasil mengamankan ketersediaan informasi sistem dari risiko kegagalan API pihak ketiga. Sistem AGRO-TANYA terbukti handal dalam menjembatani kesenjangan makna antara bahasa awam masyarakat tani dengan terminologi ilmiah dokumen penyuluhan pertanian di Indonesia.

Kata Kunci: *Information Retrieval, Retrieval-Augmented Generation, Semantic Search, BGE-M3, ChromaDB.*

Abstract— The agricultural sector in the Parepare region, particularly for rice and maize commodities, faces serious constraints in disseminating extension information due to the Semantic Gap phenomenon. Farmers communicating in colloquial or casual language frequently fail to retrieve technical insights from official guideline documents when relying on conventional keyword-based search engines. This research aims to evaluate the precision of natural language semantic retrieval through the development of a Question-Answering (QA) system named AGRO-TANYA, which implements a Retrieval-Augmented Generation (RAG) architecture. The knowledge base was independently constructed by extracting 1,332 agricultural PDF journals from the Garuda portal into 20,200 rows of structured paragraph chunks. A comparative analysis was conducted across three dense vector embedding models: *paraphrase-multilingual-MiniLM-L12-v2*, *intfloat/multilingual-e5-large*, and *BAAI/bge-m3*. Quantitative evaluation indicates that the 1024-dimensional BAAI/bge-m3 model demonstrates superior performance, achieving a Mean Reciprocal Rank (MRR) of 0.667, a Precision@3 of 0.56, and a HitRate@3 of 66.7%, significantly outperforming the baseline MiniLM model which suffered from complete lexical vocabulary mismatch. On the generation layer, integrating the Gemini 2.5 Flash model with Advanced Prompt Engineering techniques empirically succeeded in synthesizing factual, localized responses infusing Bugis-Makassar social expressions, while remaining entirely hallucination-free. From a system reliability perspective, the implementation of an Asymmetric Context Window and a Graceful Degradation mechanism successfully preserved information availability against external API rate-limiting failures. The AGRO-TANYA system proves empirically effective in bridging the linguistic gap between standard farmers' expressions and complex academic terminologies within Indonesian agricultural extension corpora.

Keywords: *Information Retrieval, Retrieval-Augmented Generation, Semantic Search, BGE-M3, ChromaDB.*

1. PENDAHULUAN

Sektor pertanian, khususnya komoditas padi dan jagung, merupakan tulang punggung ketahanan pangan di wilayah Ajatappareng, termasuk Kota Parepare [1]. Dalam upaya mitigasi gagal panen akibat hama dan penyakit, petani sangat bergantung pada informasi penyuluhan dari Kementerian Pertanian dan Balai Pengkajian Teknologi Pertanian (BPTP) [2]. Namun, ketersediaan tenaga penyuluh lapangan seringkali tidak sebanding dengan luasnya wilayah dan kebutuhan informasi yang bersifat real-time.

Saat ini, pemerintah telah menyediakan ribuan dokumen teknis dan panduan budidaya secara daring [3]. Sayangnya, akses terhadap informasi tersebut terhambat oleh fenomena Semantic Gap (kesenjangan semantik). Petani awam sering menggunakan bahasa keseharian atau gejala visual, misalnya "daun jagung bule" atau "pucuk dimakan ulat" saat mencari informasi. Di sisi lain, mesin pencari konvensional berbasis kata kunci (seperti TF-IDF/BM25) hanya memunculkan hasil jika kueri tersebut cocok dengan bahasa akademis dalam dokumen, misalnya "Peronosclerospora" atau "Spodoptera frugiperda" [4]. Hal ini menyebabkan informasi yang relevan gagal ditemukan (low recall).

Berbagai penelitian telah mengkaji pengembangan chatbot dan sistem temu kembali informasi untuk domain pertanian. Silva et al. [5] mengembangkan Farmer.Chat menggunakan arsitektur RAG dengan LLM yang terbukti efektif mengolah data tidak terstruktur sehingga informasi lebih akurat dan andal dibanding LLM tanpa retrieval. Samudra et al. [6] mengembangkan chatbot berbasis PDF menggunakan Local RAG dengan ChromaDB sebagai vector database dan model embedding `nomic_embed_text` yang berhasil memahami isi dokumen dan memberikan jawaban relevan. Ramdan et al. [7] membangun sistem konsultasi petani berbasis web menggunakan chatbot yang memfasilitasi tanya jawab antara petani dan pakar. Yasmin dan Fudholi [8] mengembangkan sistem helpdesk berbasis RAG menggunakan Gemini 1.5 Flash yang memperoleh skor aksesibilitas 89 pada pengujian Google Lighthouse. Mufidah [9] mengintegrasikan kerangka RAG menggunakan indexing vektor FAISS/Chroma dengan IndoBERT untuk semantic search, menghasilkan precision 0,828 dan F1-Score 0,854. Penelitian-penelitian tersebut membuktikan potensi RAG, namun belum spesifik menangani semantic gap dalam konteks penyuluhan pertanian lokal berbahasa Indonesia.

GAP yang ditemukan dari kajian literatur adalah belum adanya sistem yang secara khusus menggabungkan Dense Vector Embedding berkualitas tinggi dengan arsitektur RAG untuk menjembatani kesenjangan semantik antara bahasa awam petani lokal dengan terminologi ilmiah dalam corpus penyuluhan pertanian berbahasa Indonesia. Penelitian ini mengisi gap tersebut dengan mengusulkan Sistem AGRO-TANYA sebuah QA System yang mengimplementasikan arsitektur RAG berbasis Semantic Search. Dengan memanfaatkan model representasi bahasa multilingual (Dense Vector Embedding) dan sintesis dari Large Language Model (LLM), sistem ini dirancang untuk mencari dan merangkum potongan dokumen penyuluhan secara spesifik, akurat, dan bebas dari halusinasi faktual.

Tujuan penelitian ini adalah: (1) mengukur tingkat relevansi dan akurasi jawaban sistem AGRO-TANYA dalam merespons pertanyaan seputar budidaya padi dan jagung, (2) menganalisis efektivitas kombinasi arsitektur RAG, Dense Vector Embedding, dan algoritma KNN Cosine Similarity, serta (3) menilai kualitas output generatif LLM dalam memproduksi respons yang informatif dan mudah dipahami petani.

2. KAJIAN LITERATUR

2.1 Information Retrieval dan Semantic Gap

Information Retrieval (IR) adalah cabang ilmu komputer yang berfokus pada representasi, penyimpanan, pengorganisasian, dan akses terhadap informasi dari kumpulan data tidak terstruktur. Berbeda dengan basis data relasional yang bekerja berdasarkan kueri terstruktur, sistem IR harus menghadapi ambiguitas bahasa manusia. Penelitian tentang sistem pencarian berbasis semantik mengonfirmasi bahwa pendekatan ini secara signifikan meningkatkan akurasi hasil dibanding pencarian berbasis kata kunci konvensional [4]. Kesenjangan semantik (Semantic Gap) adalah disparitas kosakata antara bahasa deskriptif pengguna awam dengan terminologi akademis dalam dokumen, yang menyebabkan nilai recall sangat rendah pada sistem berbasis leksikal [10].

2.2 Dense Vector Embedding dan Model BAAI/bge-m3

Dense Vector Embedding memetakan teks ke dalam ruang vektor berdimensi padat dan tetap, di mana teks bermakna serupa dikomputasi pada titik koordinat yang berdekatan. Teknologi ini dicapai melalui arsitektur Sentence-Transformers berbasis Transformer (BERT) yang membaca keseluruhan kalimat dan memproduksi satu vektor yang mengenkapsulasi makna konteks [11]. BAAI/bge-m3 adalah model embedding mutakhir dari Beijing Academy of Artificial Intelligence yang mendukung tiga paradigma retrieval sekaligus: Dense Retrieval, Sparse Retrieval, dan Multi-Vector Retrieval (ColBERT-style). Model ini mendukung lebih dari 100 bahasa termasuk Bahasa Indonesia dengan panjang teks hingga 8.192 token [8].

2.3 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) adalah paradigma arsitektur yang mengawinkan kemampuan pencarian IR konvensional dengan kemampuan generatif LLM. RAG beroperasi dalam dua fase: (1) fase Retrieval—mencari dan mengekstrak potongan teks paling relevan dari basis data vektor lokal; (2) fase Generation—merangkai teks acuan menjadi jawaban komprehensif menggunakan LLM. Implementasi RAG terbukti secara konsisten meminimalkan halusinasi faktual karena model dikunci pada dokumen referensi eksternal [12]. Sistem RAG chatbot informasi perusahaan yang diuji dengan UAT dari 5 karyawan menghasilkan persentase kelayakan 99,2% [13].

2.4 Vector Database dan Algoritma KNN Cosine Similarity

Vector Database seperti ChromaDB dirancang khusus untuk mengelola dan melakukan komputasi penelusuran jutaan vector embeddings secara efisien. Algoritma K-Nearest Neighbors (KNN) mencari K titik vektor paling dekat dengan vektor kueri menggunakan pengukuran Cosine Similarity: $\text{sim}(A,B) = (A \cdot B) / (\|A\| \times \|B\|)$, dengan nilai mendekati 1 menunjukkan kemiripan semantik sangat tinggi. Sistem RAG berbasis ChromaDB dan Ollama membuktikan kemampuannya memahami isi dokumen PDF dan memberikan jawaban relevan berdasarkan konteks [6].

2.5 Evaluasi Sistem IR: MRR dan Precision@K

Mean Reciprocal Rank (MRR) mengukur seberapa efektif sistem menempatkan dokumen relevan pada peringkat teratas: $\text{MRR} = (1/|Q|) \times \sum (1/\text{rank}_u)$. Precision@K mengukur jumlah dokumen relevan di antara K hasil teratas. Sistem RAG chatbot kesehatan berbahasa Indonesia menghasilkan MRR 93% dan Semantic Similarity 81% [14]. Pendekatan Synonym-Aware Evaluation digunakan untuk memastikan metrik evaluasi mencerminkan kemampuan sistem sesungguhnya dalam melayani bahasa awam petani, bukan hanya bahasa akademis dokumen [10].

3. METODOLOGI PENELITIAN

3.1 Alat dan Teknologi yang Digunakan

Penelitian ini memanfaatkan sejumlah teknologi inti yang membentuk arsitektur sistem AGRO-TANYA. Berikut adalah komponen teknologi utama yang digunakan:

Tabel 1. Teknologi Utama Sistem AGRO-TANYA

Komponen	Teknologi/Library Utama	Fungsi
Antarmuka Web	Streamlit v1.31.1	Framework untuk membangun UI chatbot interaktif
Vector Database	ChromaDB v0.4.22 + pysqlite3-binary v0.5.2	Penyimpanan dan pencarian vector embedding
Embedding Model	Sentence-Transformers v2.3.1 + BAAI/bge-m3	Konversi teks menjadi representasi vektor semantik
Large Language Model	Google Generative AI SDK v0.3.1 (Gemini 2.5 Flash)	Generasi jawaban berbahasa alami dari konteks retrieval
Data Processing	Pandas v2.1.4	Manipulasi data CSV corpus pertanian

3.2 Pengumpulan dan Pra-Pemrosesan Data

Data yang digunakan berupa artikel dan jurnal ilmiah pertanian, khususnya budidaya padi dan jagung, yang diperoleh dari portal Garuda (Garba Rujukan Digital). Sebanyak 1.332 dokumen PDF berhasil dikumpulkan sebagai Dataset Garuda v2. Alur pra-pemrosesan mencakup tahapan berurutan: (1) Pengunduhan massal 1.332 file PDF menggunakan skrip Python otomatis; (2) Ekstraksi teks dari setiap PDF menggunakan skrip Jupyter Notebook secara massal; (3) Pembersihan (Cleaning) dengan menghapus karakter tidak diperlukan dan noise; (4) Penyimpanan ke CSV menghasilkan 20.200 baris/paragraf terstruktur; serta (5) Vektorisasi ke ChromaDB menggunakan model BAAI/bge-m3. Proses chunking bertujuan mempermudah sistem menemukan informasi relevan dan meningkatkan akurasi pencarian pada tahap retrieval.

3.3 Vektorisasi dan Indexing pada Vector Database

Setiap potongan teks diubah menjadi vector embedding menggunakan model Sentence-Transformers BAAI/bge-m3, yang menghasilkan representasi numerik berdimensi 1024 per potongan teks. Seluruh vektor disimpan ke ChromaDB menggunakan teknik batch processing per 5.000 data untuk menghemat memori. Setiap vektor diindeks bersama metadata (sumber dokumen dan teks asli) untuk memungkinkan pencarian semantik berkecepatan tinggi. ChromaDB dipilih karena kemampuannya melakukan pencarian kemiripan antar vektor jauh lebih cepat dan efisien dibanding basis data konvensional.

3.4 Proses Retrieval: KNN dan Asymmetric Context Window

Ketika pengguna mengajukan pertanyaan, sistem mengubah pertanyaan menjadi vector embedding menggunakan model yang sama dengan proses vektorisasi. Sistem kemudian melakukan pencarian pada ChromaDB menggunakan algoritma K-Nearest Neighbors (KNN) dengan metode Cosine Similarity untuk menemukan dokumen paling relevan. Sistem AGRO-TANYA mengimplementasikan strategi Asymmetric Context Window: sistem mengambil Top-5 dokumen ($K=5$) sebagai konteks bagi LLM Gemini 2.5 Flash untuk menghasilkan jawaban yang lebih luas dan akurat, namun antarmuka pengguna hanya menampilkan Top-3 dokumen sebagai referensi sumber, menjaga tampilan tetap bersih dan tidak membebani kognitif petani.

3.5 Generation Menggunakan RAG dan Graceful Degradation

Tahap generation menggabungkan pertanyaan pengguna dan hasil retrieval, kemudian mengirimkannya ke Gemini 2.5 Flash melalui Advanced Prompt Engineering. Model dikonfigurasi sebagai 'Penyuluh Pintar' wilayah Sulawesi Selatan yang menjawab secara akurat dengan nuansa lokal. Untuk menjamin ketersediaan sistem, AGRO-TANYA mengimplementasikan mekanisme Graceful Degradation: ketika API Gemini mengembalikan error HTTP 429 (Too Many Requests/kuota habis), sistem secara otomatis beralih ke mode Mesin Pencari Klasik yang menampilkan teks jurnal hasil retrieval ChromaDB secara langsung tanpa LLM, sehingga sistem tidak pernah benar-benar mati.

3.6 Evaluasi Sistem

Evaluasi dilakukan menggunakan dua metrik standar IR: Mean Reciprocal Rank (MRR) dan Precision@K. Pengujian menggunakan pertanyaan uji yang berkaitan dengan budidaya, hama, dan penyakit tanaman padi dan jagung. Setiap pertanyaan diproses oleh sistem dan hasilnya dibandingkan dengan dokumen ground truth. Tiga model embedding diuji secara komparatif untuk menentukan model terbaik sebagai mesin embedding sistem.

4. HASIL DAN PEMBAHASAN

4.1 Hasil Pra-Pemrosesan dan Pembangunan Corpus


Tahap pra-pemrosesan berhasil mengkonversi 1.332 dokumen PDF jurnal ilmiah pertanian dari portal Garuda menjadi korpus informasi pertanian terstruktur. Berdasarkan hasil ekstraksi, diperoleh total 20.200 baris paragraf instruksi teknis yang tersimpan dalam berkas Dataset_Siap_Pakai_V2.csv. Data tersebut telah melalui tahap normalisasi teks dan pembersihan duplikasi, dengan ukuran rata-rata chunking sebesar 80-100 kata. Seluruh data tersebut telah terindeks sepenuhnya ke dalam basis data vektor ChromaDB, siap untuk digunakan dalam alur penelusuran semantik.

4.2 Evaluasi Komparatif Model Embedding

Pengujian komparatif kuantitatif dilakukan terhadap tiga model embedding untuk menentukan model terbaik. Hasil evaluasi disajikan pada Tabel 2 berikut:

Tabel 2. Hasil Evaluasi Komparatif Tiga Model Embedding

Model Embedding	HitRate@3	Precision@3	MRR Score	Waktu (dtk)
paraphrase-multilingual-MiniLM-L12-v2	0,0%	0,00	0,000	0,16
BAAI/bge-m3 (Terpilih)	66,7%	0,56	0,667	0,36
intfloat/multilingual-e5-large	66,7%	0,44	0,500	0,36



Gambar 1. Grafik Perbandingan Kinerja Tiga Model Embedding

Berdasarkan Tabel 2 dan Gambar 1, model *paraphrase-multilingual-MiniLM-L12-v2* mengalami kegagalan total dengan skor MRR 0,000. Kegagalan ini diakibatkan oleh dimensi vektor 384 yang terlalu rendah sehingga gagal memetakan kerumitan semantik pada terminologi pertanian. Model *BAAI/bge-m3* dengan dimensi 1024 terbukti sebagai arsitektur terbaik (MRR: 0,667; Precision@3: 0,56), melampaui *intfloat/multilingual-e5-large* yang memiliki *HitRate@3* setara (66,7%) namun nilai MRR lebih rendah. Keunggulan *bge-m3* didukung oleh arsitektur *multi-granularity* dan kapasitas konteks hingga 8.192 token, yang sangat krusial dalam menangani dokumen teknis panjang.

4.3 Hasil Pengujian Retrieval

Pengujian retrieval dilakukan menggunakan tiga pertanyaan uji representatif dengan model BAAI/bge-m3. Hasil pengujian menunjukkan kinerja retrieval yang konsisten pada domain pertanian padi dan jagung:

Tabel 3. Ringkasan Hasil Pengujian Retrieval

Kueri	Top-1 Dokumen (Cuplikan)	Cos. Sim.	Status
-------	--------------------------	-----------	--------

"Kapan waktu yang tepat memberi pupuk urea pada jagung?"	Pemberian pupuk nitrogen dilakukan sesuai taraf perlakuan. Pupuk urea diaplikasikan secara bertahap...	0,4293	Relevan (HIT)
"Hama padi yang paling berbahaya?"	Hama utama pada tanaman padi yang dapat menggagalkan panen adalah hama wereng batang coklat (Hemiptera: Delphacidae)...	0,3242	Relevan (HIT)
"Kapan waktu yang tepat untuk panen padi?"	Panen dan Pasca Panen: Waktu panen bila tanaman sudah cukup tua. Tanda padi siap panen jika bulir sudah...	0,3459	Relevan (HIT)

Seluruh tiga kueri uji menghasilkan status Relevan (HIT), menunjukkan bahwa sistem berhasil menemukan dokumen yang tepat pada posisi teratas. Nilai cosine similarity tertinggi (0,4293) diperoleh pada kueri tentang pupuk urea jagung, yang merupakan topik dengan terminologi lebih spesifik dalam corpus. Sistem juga berhasil menemukan dokumen tentang hama wereng batang coklat meskipun kueri ditulis dengan bahasa umum "hama padi yang paling berbahaya", membuktikan kemampuan sistem dalam menjembatani semantic gap.

4.4 Kualitas Generation dan Pengujian Anti-Halusinasi

Komponen generation menggunakan Gemini 2.5 Flash dengan Advanced Prompt Engineering berhasil menghasilkan jawaban yang faktual, komunikatif, dan terhindar dari halusinasi. Sistem dikonfigurasi sebagai 'Penyuluh Pintar' Sulawesi Selatan dengan partikel sapaan lokal Bugis-Makassar (Tabe' Daeng, iye', ki', pale', di') untuk meningkatkan keterbacaan bagi petani lokal.

Pengujian anti-halusinasi menggunakan kueri non-teknis berupa sapaan santun ("Assalamualaikum, alhamdulillah hari ini cuaca cerah") membuktikan ketangguhan sistem. Meskipun ChromaDB secara matematis menarik dokumen bagian 'Kata Pengantar' yang mengandung kata "Alhamdulillah", kecerdasan instruksi RAG berhasil mengabaikan dokumen tersebut dan merespons murni sebagai fungsi interaksi sosial yang ramah, tanpa menciptakan informasi pertanian yang tidak relevan.

Strategi Asymmetric Context Window (Top-5 untuk LLM, Top-3 untuk UI) terbukti efektif dalam mengoptimalkan kualitas jawaban sekaligus menjaga kebersihan tampilan antarmuka. Mekanisme Graceful Degradation juga berhasil divalidasi: ketika API mengalami error 429, sistem secara transparan beralih ke mode pencarian klasik berbasis ChromaDB tanpa mengganggu ketersediaan layanan informasi bagi petani.

5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil mengembangkan Sistem AGRO-TANYA, sistem temu kembali informasi berbasis tanya-jawab chatbot menggunakan arsitektur Retrieval-Augmented Generation (RAG) untuk domain penyuluhan pertanian wilayah Parepare. Beberapa kesimpulan utama yang dapat ditarik adalah:

Pertama, pipeline pra-pemrosesan data berhasil mengkonversi 1.332 dokumen PDF dari portal Garuda menjadi corpus bersih sebanyak 20.200 baris paragraf pertanian yang terstruktur dan siap digunakan sebagai basis pengetahuan sistem.

Kedua, pengujian komparatif tiga model embedding membuktikan bahwa model BAAI/bge-m3 (1024 dimensi) memberikan performa terbaik dengan MRR 0,667 dan Precision@3 sebesar 0,56, secara signifikan mengungguli model paraphrase-multilingual-MiniLM-L12-v2 yang mengalami kegagalan total (MRR: 0,000) dan intfloat/multilingual-e5-large (MRR: 0,500).

Ketiga, integrasi komponen Retrieval (ChromaDB + BAAI/bge-m3) dengan komponen Generation (Gemini 2.5 Flash) melalui Advanced Prompt Engineering berhasil menghasilkan sistem tanya-jawab yang 100% grounded pada dokumen acuan, mampu memitigasi halusinasi faktual, dan menghasilkan respons dalam nuansa bahasa lokal Parepare.

Keempat, implementasi Asymmetric Context Window dan Graceful Degradation terbukti meningkatkan kualitas jawaban LLM sekaligus menjamin ketersediaan sistem meskipun terjadi kegagalan API eksternal.

5.2 Saran

Untuk pengembangan lebih lanjut, beberapa rekomendasi strategis diusulkan: (1) Implementasi Native Hybrid Search pada ChromaDB dengan mengombinasikan Dense Vector Retrieval dan algoritma BM25 untuk menutup celah kegagalan pencarian pada istilah sangat spesifik; (2) Evolusi menuju Multi-Modal RAG dengan integrasi Vision AI (seperti YOLOv8) agar sistem dapat menerima input gambar kondisi fisik tanaman dari lapangan; (3) Fine-tuning model BAAI/bge-m3 menggunakan corpus glosarium istilah pertanian Sulawesi Selatan (IndoAgriBERT Embedding); dan (4) Ekspansi basis pengetahuan ke komoditas hortikultura strategis lainnya seperti cabai, bawang merah, dan kakao.

6. ACKNOWLEDGEMENT

Penulis mengucapkan terima kasih kepada Ibu Mardhiyyah Rafrin, S.T., M.Sc. selaku dosen pengampu mata kuliah Perolehan Informasi atas segala bimbingan dan arahan dalam penelitian ini. Terima kasih juga kepada Program Studi Ilmu Komputer, Institut Teknologi Bacharuddin Jusuf Habibie (ITH), yang telah memfasilitasi lingkungan akademik yang inspiratif.

Penulis menyatakan bahwa dalam penelitian ini, kecerdasan buatan (AI) digunakan untuk beberapa tujuan: (1) membantu penulisan dan penyempurnaan source code sistem AGRO-TANYA, khususnya pada implementasi pipeline RAG, konfigurasi ChromaDB, dan pengembangan antarmuka Streamlit; (2) sebagai referensi teknis dan petunjuk dalam debugging kode; (3) membantu dalam pencarian dan identifikasi referensi ilmiah yang relevan; serta (4) membantu dalam penyempurnaan penulisan laporan akademik. Seluruh konsep penelitian, desain sistem, analisis data, dan interpretasi hasil tetap merupakan hasil pemikiran dan kerja tim peneliti.

REFERENSI

- [1] N. Somba, S. Mansyur, dan M. Nur, "Mistifikasi Ritual Sistem Pertanian Tradisional Masyarakat Ajatappareng Sulawesi Selatan," ResearchGate, 2019. [Online]. Tersedia: <https://www.researchgate.net/publication/338947302>
- [2] A. Al Ardy et al., Teknik Budidaya Tanaman Pangan. Palembang: Universitas Sriwijaya, 2023.
- [3] B. Winarko, H. Junaidi, dan M. Sinuraya, Panduan Teknis Budidaya Tanaman Pangan. Jakarta: Kementerian Pertanian Republik Indonesia, 2021.
- [4] A. Asmaidin dan C. B. Santoso, "Sistem Pencarian Berbasis Semantik untuk Peningkatan Akurasi Hasil Temu Kembali Informasi," J-INTECH: Journal of Information and Technology, 2026. doi: <https://jurnal.ubhinus.ac.id/index.php/J-INTECH/article/view/2252>
- [5] J. G. Silva et al., "Farmer.Chat: Scaling AI-Powered Agricultural Services for Smallholder Farmers," arXiv preprint arXiv:2409.08916, 2024.
- [6] G. Samudra, A. T. Zy, dan Ermanto, "Pengembangan Chatbot Berbasis PDF Menggunakan Local Retrieval-Augmented Generation (RAG) dan Ollama," JSAI: Journal of Sustainable Artificial Intelligence, vol. 8, no. 1, 2025. doi: 10.36085/jsai.v8i1
- [7] Ramdan et al., "Sistem Informasi Konsultasi Petani Berbasis Web Menggunakan Chatbot," JNKTI: Jurnal Nasional Komputasi dan Teknologi Informasi, 2024. [Online]. Tersedia: <https://ojs.serambimekkah.ac.id/jnkti/article/view/7913>
- [8] S. M. Yasmin dan D. H. Fudholi, "Pengembangan Sistem Helpdesk Menggunakan Chatbot dengan Metode Retrieval Augmented Generation (RAG)," JPTI: Jurnal Pendidikan Teknologi Informasi, 2025. doi: 10.52436/1.jpti.995
- [9] A. Mufidah, "Integrasi Kerangka Kerja RAG Menggunakan Indexing Vektor FAISS/Chroma dan IndoBERT untuk Semantic Search," Nusantara of Engineering (NoE), 2025. [Online]. Tersedia: <https://ojs.unpkediri.ac.id/index.php/noe/article/view/26866>
- [10] Pujiono et al., "Evaluasi Sistem Temu Kembali Informasi Domain Khusus Menggunakan Metode Pencarian Semantik Berbasis Vektor," JSAI: Journal of Sustainable Artificial Intelligence, 2024. [Online]. Tersedia: <https://jurnal.umb.ac.id/index.php/JSAI/article/view/9897>

- [11] Albert dan A. Voutama, "Pengembangan Chatbot Berbasis PDF Menggunakan Local Retrieval-Augmented Generation (RAG) dan Ollama," *JITET: Journal of Informatics and Technology Education*, vol. 13, no. 2, 2025. doi: 10.23960/jitet.v13i2.6361
- [12] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [Online]. Tersedia: <https://arxiv.org/abs/2005.11401>
- [13] Raya dan Cahyanti, "Sistem RAG Chatbot Informasi Perusahaan: Evaluasi UAT dan Kelayakan Sistem," *Jurnal Ilmiah Teknologi Informasi*, 2025. doi: 10.31294/m75d4782
- [14] Tasrif et al., "Sistem RAG Chatbot Kesehatan Berbahasa Indonesia Menggunakan Model Indo-Sentence-BERT," *JSAI: Journal of Sustainable Artificial Intelligence*, 2025. [Online]. Tersedia: <https://jurnal.umb.ac.id/index.php/JSAI/article/view/7678>